

A. Ζητούμενο

Κατασκευάστε **λεκτικό αναλυτή** για το μορφότυπο **JSON5**. Θα βρείτε τη σχετική προδιαγραφή στο <https://spec.json5.org/>.

Για την κατασκευή θα πρέπει να χρησιμοποιηθεί υποχρεωτικά η κλάση **Tokenizer** που βρίσκεται στη βιβλιοθήκη Python **compilerlabs** του εργαστηρίου. Η τεκμηρίωση και παραδείγματα χρήσης της κλάσης αυτής βρίσκονται στα links:

<https://mixstef.github.io/courses/compilers/lecturedoc/02-regex/tokenizer.html>

<https://mixstef.github.io/courses/compilers/tokenizer-notes.pdf>

Η ανάπτυξη του κώδικα θα πρέπει να γίνει σε **jupyter notebook**, στο περιβάλλον εκτέλεσης του εργαστηρίου: <https://mybinder.org/v2/gh/mixstef/mybinder-compilers/HEAD>

Στο notebook που θα παραδώσετε θα πρέπει να φαίνονται και τα αποτελέσματα εκτέλεσης του λεκτικού αναλυτή.

Προσοχή: Στο ζητούμενο της εργασίας δεν περιλαμβάνεται η συντακτική ανάλυση.

B. Διαδικασία επίλυσης

Ακολουθήστε τα παρακάτω βήματα για τη δημιουργία του κώδικα υλοποίησης σε Python. Οι ερωτήσεις (με αρίθμηση E.x) που τίθενται σε κάθε στάδιο θα πρέπει να απαντηθούν στη συνοδευτική αναφορά που θα παραδώσετε μαζί με τον κώδικα.

1. Προσδιορισμός tokens

Βρείτε τα διαφορετικά είδη tokens που απαιτούνται για την ανάλυση κειμένου σε μορφή JSON5, σύμφωνα με την προδιαγραφή στο <https://spec.json5.org/>. Δείτε και την ενότητα 9.1 της προδιαγραφής (<https://spec.json5.org/#lexical-grammar>) για να βοηθηθείτε.

(E.1) Παραθέστε πίνακα με τα διαφορετικά είδη tokens που απαιτούνται, μαζί με εξήγηση για τη μορφή κειμένου που αντιπροσωπεύει το κάθε token.

2. Εύρεση κανονικών εκφράσεων

Στη συνέχεια θα πρέπει να βρείτε ποια κανονική έκφραση αντιστοιχεί στα tokens που έχετε αναγνωρίσει προηγουμένως. Οι κανονικές εκφράσεις που θα χρησιμοποιήσετε θα πρέπει να υποστηρίζονται από το module re της standard library της Python.

(E.2) Για κάθε ένα από τα tokens (ή ομάδα από tokens) που έχετε προηγουμένως προσδιορίσει, παραθέστε σε μορφή πίνακα την αντίστοιχη κανονική έκφραση, με μια συνοπτική εξήγηση σε κάθε περίπτωση για τον τρόπο με τον οποίο καλύπτεται ο ορισμός του token στην προδιαγραφή JSON5.

(E.3) Σε περίπτωση που δεν μπορέσατε να καλύψετε πλήρως κάποιο token της προδιαγραφής JSON5, σημειώστε εδώ ποιο είναι αυτό και πόσο απέχει η λύση σας από την προδιαγραφή.

Προσοχή: Για τις ανάγκες της άσκησης θεωρήστε ότι τα γράμματα σε ένα IdentifierName ανήκουν μόνο στον κώδικα ASCII.

3. Σειρά δήλωσης patterns

Γνωρίζοντας ότι η κλάση Tokenizer χρησιμοποιεί την εναλλαγή (|) για την εύρεση των διαφορετικών tokens, προσδιορίστε τη σειρά με την οποία θα δηλώσετε τα patterns των κανονικών εκφράσεων του Tokenizer.

(E.4) Παραθέστε με σειρά προτεραιότητας τις κανονικές εκφράσεις που θα δηλώσετε ως patterns στον Tokenizer. Μην ξεχάσετε να προσθέσετε το pattern για την αφαίρεση χαρακτήρων white-space και το τελικό pattern που θα δημιουργεί σφάλμα σε περίπτωση μη άλλης αναγνώρισης. Για κάθε pattern που πρέπει να δηλωθεί πριν κάποιο άλλο, αναγράψτε μια σχετική σημείωση δίπλα στο pattern.

4. Κατασκευή κώδικα και δοκιμαστικού κειμένου εισόδου

Κατασκευάστε τον κώδικα του λεκτικού αναλυτή JSON5 σύμφωνα με τις απαντήσεις σας στα προηγούμενα ερωτήματα (E.1-4). Κατασκευάστε επίσης δοκιμαστικό κείμενο JSON5, το οποίο θα πρέπει να καλύπτει όλα τα είδη tokens που αναγνωρίζετε.

(E.5) Παραθέστε το δοκιμαστικό κείμενο JSON5 που χρησιμοποιείτε και σημειώστε ποιο είδος token αναγνωρίζεται σε κάθε σημείο του.

5. Αναφορές

(E.6) Παραθέστε τις πηγές που χρησιμοποιήσατε για την επίλυση της εργασίας (εκτός από το υλικό του εργαστηρίου).

(E.7) Σε περίπτωση χρήσης εργαλείων TN περιγράψτε σε ποιο στάδιο χρησιμοποιήθηκαν και με ποιον τρόπο.

Γ. Παραδοτέο

i) Όταν έχετε ολοκληρώσει την επίλυση της εργασίας, περάστε τον τελικό κώδικα σε ένα jupyter notebook (αν δεν χρησιμοποιείτε notebook από την αρχή). Εκτελέστε τον συνολικό κώδικα με το δοκιμαστικό κείμενο JSON5. Τα αποτελέσματα των δοκιμών θα πρέπει να εκτυπωθούν και να φαίνονται στο τελικό jupyter notebook που θα παραδώσετε.

ii) Ετοιμάστε αναφορά σε μορφή pdf με τις απαντήσεις σας στα ερωτήματα E.x των προηγούμενων ενοτήτων.

Ανεβάστε το τελικό σας notebook και την αναφορά pdf σε ένα μοναδικό αρχείο zip στο opencourses (**Εργασία 1**) έως και τη **Δευτέρα 6/4**.

Βαθμολόγηση εργασίας

Κριτήριο	% βαθμού
Επιτυχής συγγραφή κώδικα με ορθή εμφάνιση αποτελεσμάτων	40%
Πλήρεις και τεκμηριωμένες απαντήσεις των ερωτημάτων στην αναφορά	60%