

Μεταγλωττιστές 2024-25

Εισαγωγή στη Συντακτική Ανάλυση

Πού είμαστε τώρα

- Έχουμε ολοκληρώσει τη θεωρία της **λεκτικής ανάλυσης**
- Και έχουμε δει εργαλεία για τη δημιουργία ενός **λεκτικού αναλυτή** σε καθαρή Python
 - κλάση **Tokenizer** από το module **compilerlabs**
- Ο λεκτικός αναλυτής καταναλώνει **χαρακτήρες** από την είσοδο και παράγει **σύμβολα** (tokens)
 - Τα σύμβολα αυτά χρησιμοποιούνται ως είσοδος στο επόμενο στάδιο, αυτό της **συντακτικής ανάλυσης**

Ο πρώτος στόχος

```
a = 2 + 7.55*44  
print a  
b = 3*(a-99.01)  
print b*0.23  
c = 5-3-2  
print c
```

- Θέλουμε να υπολογίζουμε αριθμητικές εκφράσεις με μεταβλητές και να τυπώνουμε αποτελέσματα
 - Όπως στο πιο πάνω παράδειγμα
 - Αργότερα θα προσθέσουμε δομές ελέγχου – επανάληψης, συναρτήσεις...

Συντακτική Ανάλυση (Parsing)

- Μετά τη λεκτική ανάλυση
 - Είσοδος: τα σύμβολα (**tokens**) του λεκτικού αναλυτή
- Σκοπός: η ανάλυση της **δομής** της εισόδου
 - Αν είναι σωστά δομημένη σύμφωνα με τους **κανόνες σύνταξης** της εκάστοτε γλώσσας προγραμματισμού
- Έξοδος;
 - **Θεωρητικά**, τίποτα αν η είσοδος είναι συντακτικά έγκυρη
 - Ή σφάλμα σύνταξης στην αντίθετη περίπτωση
 - **Πρακτικά**;

Η συντακτική ανάλυση στην πράξη

- Κατά τη διαδικασία ανάλυσης
 - Κρατείται η πληροφορία της **δομής** της εισόδου
 - Π.χ. τι υπάρχει μέσα σε ένα if, for κλπ
- Συνδυάζεται ταυτόχρονα (ή διαδοχικά) με τη **σημασιολογική ανάλυση**
- Σύλληψη της **«έννοιας»** του προγράμματος εισόδου
 - Αυτό που θέλει να κάνει ο προγραμματιστής

Σημασιολογική ανάλυση - μια γρήγορη ματιά

- **Context-sensitive analysis**
- Τι δεν μπορεί να κάνει η συντακτική ανάλυση από μόνη της, μερικά παραδείγματα
 - Τι είναι αποθηκευμένο στο x ;
 - Τύποι μεταβλητών
 - Παράμετροι συναρτήσεων
 - Καλείται μια συνάρτηση με τις παραμέτρους που πρέπει;
 - Διάρκεια ζωής μεταβλητών

Έξοδος συντακτικής+σημασιολογικής ανάλυσης


- «Ενδιάμεση αναπαράσταση» (intermediate representation, IR)
 - Το «**νόημα**» του προγράμματος
 - Σε συστηματική αναπαράσταση
 - Έτοιμο για επεξεργασία από τα επόμενα στάδια του μεταγλωττιστή
 - Στάδια βελτιστοποίησης
 - Παραγωγή εκτελέσιμου κώδικα ή διερμηνεία (απ' ευθείας εκτέλεση)

Παράδειγμα ενδιάμεσης αναπαράστασης (AST)

- Έστω η είσοδος: $(5 - 3) * 10$
- Η λεκτική ανάλυση δίνει τα tokens:
`lparen int(5) minus int(3) rparen mult int(10)`
- **Abstract Syntax Tree (AST)**
 - **Δενδρική δομή** που αποτυπώνει το «**νόημα**» της εισόδου
 - Το νόημα εδώ: η σωστή αριθμητική ερμηνεία και η εξαγωγή αποτελέσματος από την αριθμητική έκφραση

Παράδειγμα ενδιάμεσης αναπαράστασης (AST)

- Είσοδος: $(5-3)*10$



- Κάθε κόμβος εκφράζει μια αριθμητική τιμή
 - Αν είναι **φύλλο**, εκφράζει την τιμή μιας αριθμητικής σταθεράς (5, 3 και 10)
 - Αν είναι **ενδιάμεσος κόμβος**, την τιμή που υπολογίζεται από την εφαρμογή του αντίστοιχου τελεστή ($-$ και $*$) στις τιμές των παιδιών του
- Πώς θα ήταν στην περίπτωση του $5-3*10$;
- Και στην περίπτωση του $5-3-2$;

Γιατί δεν αρκεί η λεκτική ανάλυση


- Γιατί να μην κάνουμε τα πάντα με **κανονικές εκφράσεις**;
 - Δεν μπορούμε: οι (συνήθεις) κανονικές εκφράσεις δεν αναγνωρίζουν **nested δομές** (γενικά δεν υποστηρίζουν **αναδρομή**)
 - Στην Python μόνο το third-party **regex** module υποστηρίζει αναδρομή
 - Π.χ. με τις κανονικές εκφράσεις δεν μπορούμε να αναγνωρίσουμε αν η είσοδος έχει **ισορροπημένες παρενθέσεις**
 - Ένα αυτόματο μπορεί να μας πει σε ποιο state είμαστε, όχι όμως πόσες φορές έχουμε περάσει από το state αυτό...

Μέθοδοι συντακτικής ανάλυσης

- Βασισμένες σε γραμματικές
 - Με τη μεγαλύτερη μαθηματική τυπική θεμελίωση (1960s-1970s)
 - Bonus: τεκμηρίωση για το τι κάνουμε
- Άλλες μέθοδοι
 - Λιγότερο «τυπικές», περισσότερο πρακτικές
 - Δεν υστερούν όμως σε απόδοση από τις μεθόδους με γραμματικές

Γραμματικές

- Ως «συνταγές» για την παραγωγή προτάσεων
 $SantaSays \rightarrow ho\ SantaSays \mid ho$
- Παραγωγή (production) προτάσεων (sentences)



Παραγωγή προτάσεων


- **Μη τερματικά σύμβολα**: ενδιάμεσες μορφές που πρέπει να αντικατασταθούν (π.χ. SantaSays)
- **Τερματικά σύμβολα**: οι τελικές «λέξεις» της γλώσσας που παράγει η γραμματική (π.χ. ho)
 - Τα tokens του λεκτικού αναλυτή
- Σύμφωνα με τους **κανόνες** της γραμματικής, αντικαθιστούμε τα μη τερματικά σε **βήματα παραγωγής** (productions)
 - Το αποτέλεσμα είναι σειρές από τερματικά και μη τερματικά σύμβολα (sentential forms)
 - Στο τελευταίο βήμα μένουν μόνο σειρές από τερματικά σύμβολα, οι τελικές προτάσεις (sentences)
- Για γραμματική G , η γλώσσα της γραμματικής $L(G)$ είναι το σύνολο των τελικών προτάσεων που παράγει η G

Ο φορμαλισμός της γραμματικής

- Μια γραμματική είναι η τετράδα (T, NT, S, P)
 - T το σύνολο των **τερματικών** συμβόλων
 - NT το σύνολο των **μη τερματικών**
 - $T \cap NT = \emptyset$
 - S το **αρχικό** (μη τερματικό) σύμβολο
 - P σύνολο **κανόνων** για παραγωγές
 - $(T \cup NT)^+ \rightarrow (T \cup NT)^*$

Δένδρο (ή γράφος) παραγωγής

- Προσοχή: μην το συγχέετε με ένα AST!



SantaSays
ho SantaSays
ho ho SantaSays
ho ho ho SantaSays
ho ho ho ho

Τεχνικές συντακτικής ανάλυσης

- **Top-down**
 - Ξεκινώ **από το αρχικό σύμβολο** (ρίζα δένδρου) και προσπαθώ να διαλέξω κανόνες παραγωγής που θα με οδηγήσουν **στα tokens εισόδου** (φύλλα δένδρου)
- **Bottom-up**
 - Ξεκινώ **από τα tokens εισόδου** (φύλλα δένδρου) και με βάση τους κανόνες παραγωγής προσπαθώ να φτάσω **στο αρχικό σύμβολο** (ρίζα δένδρου)

Γραμματικές κατά Chomsky

- Ιεραρχία εκφραστικής δύναμης (τι μπορούν να περιγράψουν)
- **Type 0**: χωρίς περιορισμούς μετασχηματισμοί
`comma Name End → and Name`
- **Type 1**: ένα μόνο σύμβολο στο αριστερό μέρος μετασχηματίζεται

`Name comma Name End → Name and Name End`

- Ποια η διαφορά από το απλό `comma → and`;
 - **Context-sensitive grammars**
- Δυστυχώς, για τις γραμματικές Type 0 και 1 η συντακτική ανάλυση (αν γίνεται) απαιτεί **εκθετικό χρόνο**
 - μη πρακτικό

Γραμματικές κατά Chomsky

- **Type 2**: Στο αριστερό μέρος μόνο ένα μη-τερματικό
List → **Name comma List**
 - Η αντικατάσταση ενός μη τερματικού **δεν** εξαρτάται από τα γειτονικά του (**context-free grammars**)
 - Υποστηρίζεται αναδρομή και nesting
 - Μπορούμε να θυμόμαστε **τι πρέπει να γίνει «μετά»**


Παράδειγμα

- Η γραμματική «του ασανσέρ»

Move → up Move down Move
| down Move up Move
| ε

- Σχεδιάστε το δέντρο παραγωγής για την είσοδο: up down
up up down down
- Πού θα βρίσκεται το ασανσέρ σε σχέση με την αρχική του
θέση για κάθε πρόταση που παράγει η γραμματική;
 - γιατί;

Δένδρο παραγωγής



Γραμματικές κατά Chomsky

- Γενικά, η συντακτική ανάλυση για **Type 2** γραμματικές (context-free grammars, CFG) απαιτεί χρόνο $O(n^3)$
 - μη πρακτικό
- Υπάρχουν όμως υποκατηγορίες γραμματικών που απαιτούν χρόνο $O(n)$ = πρακτική λύση!
 - Καλύπτουν σχεδόν το σύνολο των απαιτήσεων ανάλυσης των γλωσσών προγραμματισμού
 - και με τη βοήθεια της σημασιολογικής ανάλυσης
- **Type 3**: στο δεξί μέρος μόνο ένα μη τερματικό (και συνήθως αυτό στο τέλος)
 - Αδυναμία αναδρομής και nesting
 - Αντιστοιχία με τις γνωστές μας κανονικές εκφράσεις (**regular grammars**)

Η σημασία της πολυπλοκότητας

- Έστω 10.000 tokens στο πρόγραμμα εισόδου
- $O(n)$ σημαίνει 1 «ενέργεια» ανά token
 - μια ανάθεση, μια προσπέλαση κλπ
- Αν η «ενέργεια» απαιτεί 10ns, με πολυπλοκότητα $O(n)$ απαιτείται χρόνος $10 \cdot 10^{-9} \cdot 10^4 = 10^{-4}$ sec ή 100μsec.
- Με πολυπλοκότητα $O(n^3)$, δηλ. $10^{4 \cdot 3}$ «ενέργειες», πόσος θα είναι ο χρόνος συντακτικής ανάλυσης;

Ποιο μη τερματικό αντικαθιστούμε

- Σε σειρές με πολλά μη τερματικά σύμβολα (ενδιάμεσες προτασιακές μορφές), ποιο διαλέγουμε για την επόμενη αντικατάσταση;
 - **Αριστερότερη ακολουθία παραγωγών** (leftmost derivation): αντικαθιστούμε σε κάθε βήμα το **αριστερότερο** μη τερματικό
 - **Δεξιότερη ακολουθία παραγωγών** (rightmost derivation): αντικαθιστούμε σε κάθε βήμα το **δεξιότερο** μη τερματικό

Παράδειγμα

- Έστω η γραμματική

$\text{Expr} \rightarrow \text{Expr Op num} \mid \text{num}$


$\text{Op} \rightarrow + \mid - \mid * \mid /$

- Και έστω η είσοδος (tokens)


num - num * num

- Βρείτε αριστερότερη και δεξιότερη ακολουθία παραγωγών και τα αντίστοιχα δένδρα
 - Τι παρατηρείτε;
 - Αν χρησιμοποιούσαμε τα δένδρα κατευθείαν ως AST, θα είχαμε σωστή αριθμητική ερμηνεία της εισόδου;

Δενδρα παραγωγής



Αριστερότερη ακολουθία παραγωγής



Δεξιότερη ακολουθία παραγωγής

Μια καλύτερη γραμματική

$\text{Expr} \rightarrow \text{Expr} + \text{Term} \mid \text{Expr} - \text{Term} \mid \text{Term}$

$\text{Term} \rightarrow \text{Term} * \text{num} \mid \text{Term} / \text{num} \mid \text{num}$

- Ποιο το δένδρο παραγωγής για την προηγούμενη είσοδο tokens;
- Αν θέλαμε να προσθέσουμε τη δυνατότητα να υπάρχουν εκφράσεις μέσα σε παρενθέσεις δηλ. (Expr), πώς θα μπορούσαμε να το κάνουμε;
 - Υπόδειξη: σκεφτείτε τα **επίπεδα προτεραιότητας**, κάθε επίπεδο εισάγει νέο κανόνα στη γραμματική

Αμφισημία (ambiguity)

- Όταν υπάρχει **πάνω από μία** αριστερότερη (ή δεξιότερη) ακολουθία παραγωγής **για την ίδια είσοδο**
 - Αυτό σημαίνει ότι ο μεταγλωττιστής ενδεχομένως δεν θα καταλάβει αυτό που θέλουμε να πούμε!


Παράδειγμα

`Stmt → if Expr then Stmt else Stmt
 | if Expr then Stmt
 | Assignment | ..`

- Είσοδος tokens

`if E1 then if E2 then A1 else A2`

- Βρείτε δύο διαφορετικές δεξιότερες παραγωγές
 - Τι σημαίνει η κάθε μία, αν το γράφατε με τη σημερινή C;




```

if (E1) {
    if (E2) {
        A1;
    }
}
else {
    A2;
}

```

if E1 then if E2 then A1 else A2



```

if (E1) {
    if (E2) {
        A1;
    }
}
else {
    A2;
}

```

```
...  
if reactor_on then  
    if control_rods_in_place then  
        normal_operation  
    else  
        emergency_shutdown  
...  

```

- Θα θέλαμε ένα τέτοιο πρόγραμμα να ελέγχει έναν πυρηνικό αντιδραστήρα;