

Αριθμοί Κινητής Υποδιαστολής (παραδείγματα)

<https://mixstef.github.io/courses/csintro/>

Μ.Στεφανιδάκης



Αριθμοί κινητής υποδιαστολής


- Floating-point numbers
 - Οι πράξεις γίνονται στο υλικό (hardware)
 - Η αναπαράσταση είναι **προσεγγιστική** (δεν μπορεί να αναπαρασταθεί κάθε κλασματικός αριθμός!)
- Παγιωμένα πρότυπα (IEEE 754)
 - Αριθμοί απλής (C floats, 32 bits) και διπλής ακρίβειας (C doubles, 64 bits)
- Νέα πρότυπα
 - Με την άνθηση της μηχανικής μάθησης και των νευρωνικών δικτύων
 - Δεν απαιτείται μεγάλη ακρίβεια αλλά μεγάλη ταχύτητα επεξεργασίας/μικρότερο μέγεθος δεδομένων
 - Μειωμένος αριθμός bits (π.χ. 16 bit **bfloat16** format)

Αριθμοί μονής ακρίβειας (C floats)




- 32 bits (4 bytes)
 - bit 31: Πρόσημο (Π)
 - bits 30...23: Εκθέτης (E)
 - bits 22...0: Σημαινόμενο Τμήμα (Σ)
- $-1^{\text{Π}} \times 2^{\text{E}-127} \times 1.\text{Σ}$

Αριθμοί μονής ακρίβειας (C floats)




- Έστω αριθμός float με τα ακόλουθα bits: 3D CC CC CD
00111101 11001100 11001100 11001101
- Ποιος αριθμός είναι;

Αριθμοί μονής ακρίβειας (C floats)




- Έστω αριθμός float με τα ακόλουθα bits: 3D CC CC CD
00111101 11001100 11001100 11001101
- Πρόσημο: 0 (+)

Αριθμοί μονής ακρίβειας (C floats)




- Έστω αριθμός float με τα ακόλουθα bits: 3D CC CC CD
00111101 11001100 11001100 11001101
- Πρόσημο: 0 (+)
- Εκθέτης: 01111011 (123), άρα $123 - 127 = -4$
($2^{-4} = 0,0625$)

Αριθμοί μονής ακρίβειας (C floats)



- Σημαινόμενο Τμήμα
 $1.10011001100110011001101$
- Βάρη μετά την υποδιαστολή (από αριστερά προς τα δεξιά)
 $1/2^1, 1/2^2, 1/2^3, 1/2^4, \dots 1/2^{23}$

Αριθμοί μονής ακρίβειας (C floats)




- Σημαινόμενο Τμήμα

$$1/2^1 + 1/2^4 + 1/2^5 + 1/2^8 + 1/2^9 + 1/2^{12} + 1/2^{13} + 1/2^{16} + 1/2^{17} + 1/2^{20} + 1/2^{21} + 1/2^{23}$$

$$\begin{aligned} &= 0.5 + 0.0625 + 0.03125 + 0.00390625 + 0.001953125 + \\ &0.000244140625 + 0.0001220703125 + \\ &0.0000152587890625 + 0.00000762939453125 + \\ &0.00000095367431640625 + 0.000000476837158203125 + \\ &0.00000011920928955078125 \\ &= 0.60000002384185791015625 (+1.0) \end{aligned}$$

Αριθμοί μονής ακρίβειας (C floats)



- Έστω αριθμός float με τα ακόλουθα bits: 3D CC CC CD
00111101 11001100 11001100 11001101
- Πρόσημο: +
Εκθέτης: 123, $2^{123-127} = 2^{-4} = 0,0625$
- Σημαινόμενο Τμήμα: 0.600000002384185791015625 (+1.0)
- Τελικός αριθμός: + 0.1000000001490116119384765625