Προγραμματισμός σε GPUs
(το προγραμματιστικό μοντέλο CUDA)

Διασύνδεση CPU-GPU

- Διαφορετικές αρχιτεκτονικές
  - Εάν το device (GPU ή accelerator) είναι εξωτερικό: μέσω διαύλου E/E (π.χ. PCIe ή εξειδικευμένο link/bridge μεταξύ καρτών GPU)
  - Εάν το device βρίσκεται στο ίδιο chip με τη CPU: είτε μέσω εξειδικευμένου διαύλου είτε μέσω κοινής μνήμης (δηλ. το device είναι ένα διαφορετικό είδος core, παράλληλα με τα CPU cores).

Προγραμματισμός σε GPUs: ιδιαιτερότητες

- Πού εκτελείται το πρόγραμμα;
  - ένα μέρος στη CPU (“host”) και ένα μέρος σε κάποια GPU/accelerator (“device”)
- Που βρίσκονται τα δεδομένα;
  - στην κύρια μνήμη του υπολογιστή
  - σε κάποια μνήμη της GPU
    - μια τυπική GPU έχει διάφορα είδη μνήμης
    - ο προγραμματιστής πρέπει να φροντίζει για την επιλογή της πιο κατάλληλης
  - συχνά προκύπτει η ανάγκη μεταφοράς δεδομένων μεταξύ διαφορετικών μνημών
    - πρέπει να συνυπολογίζεται το κόστος μεταφοράς στη συνολική απόδοση

Οργάνωση τυπικής GPU

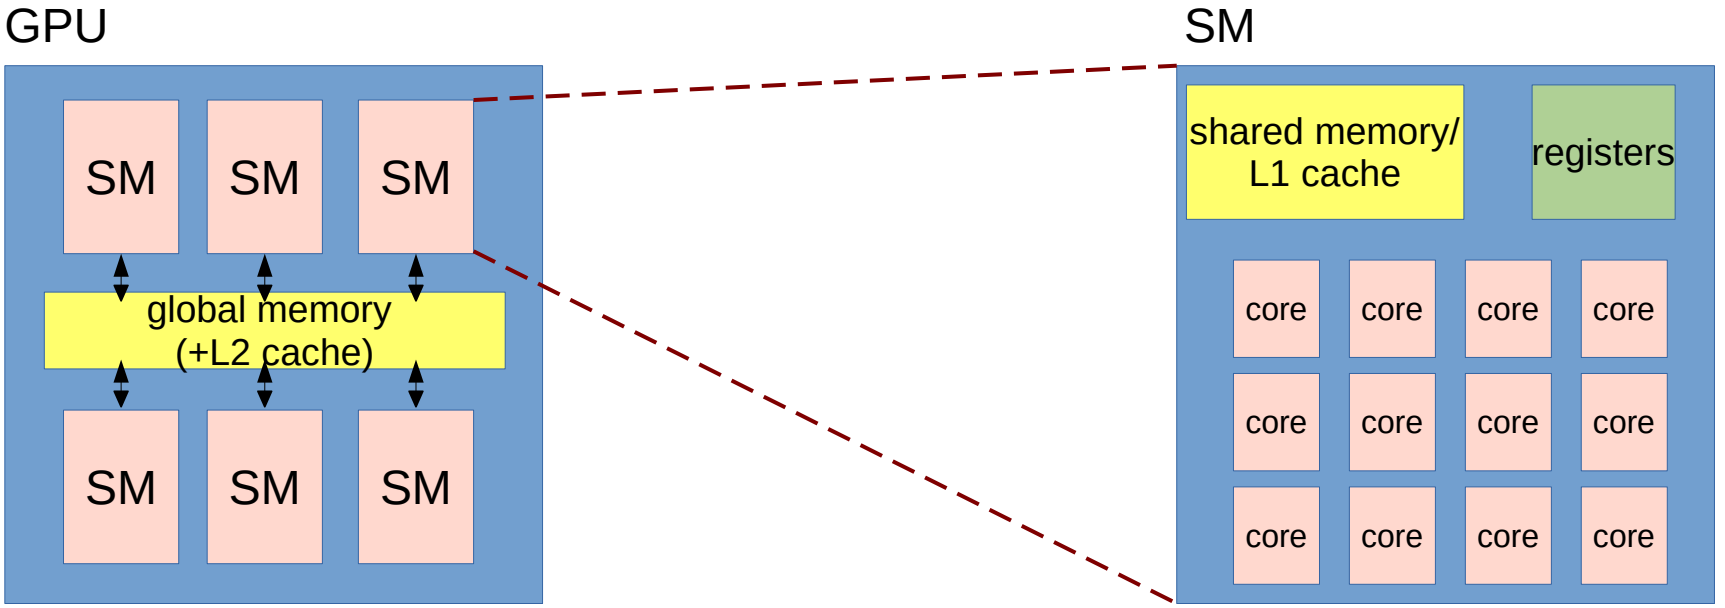

- Μια GPU αποτελείται από **Streaming Multiprocessors (SMs)**,
  - πρόσβαση όλων των SM σε global memory
- Κάθε SM διαθέτει έναν αριθμό **υπολογιστικών cores**, καθώς και ένα ξεχωριστό set καταχωρητών και μια γρήγορη κοινή μνήμη (shared memory)
  - Τα cores έχουν απλή λογική λειτουργίας, σχεδιασμένα να εκτελούν **μαζικά** πράξεις (ίδια πράξη σε μεγάλες ομάδες cores)

GPUs και threads

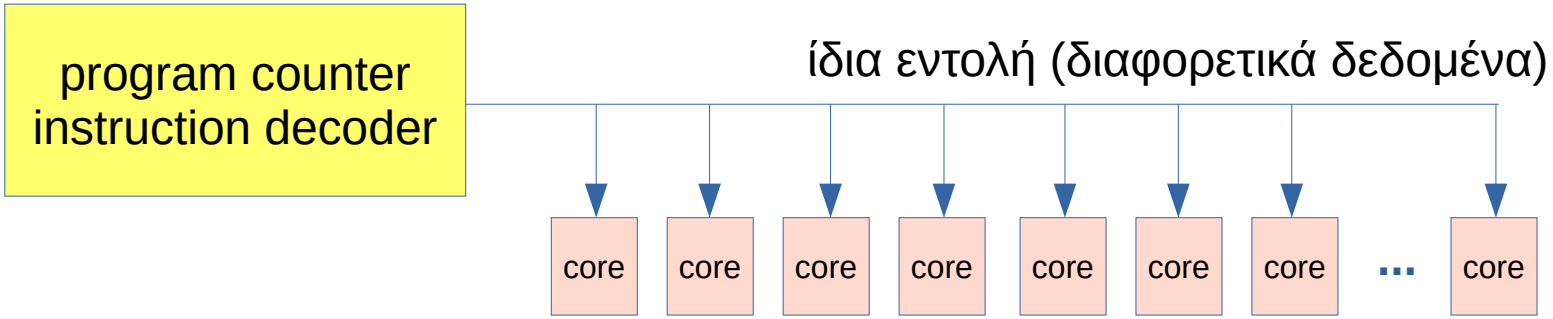

- Στις GPUs η έννοια του **thread** είναι διαφορετική απ’ ό,τι σε μια CPU
  - Διαθέσιμος (μαζικά) μεγάλος αριθμός hardware threads (cores)
  - Παράλληλη εκτέλεση της ίδιας εντολής από πολλά threads την ίδια στιγμή (μοντέλο SIMT), χωρίς επιβάρυνση: όλοι οι πόροι (state) των εκτελούμενων threads βρίσκονται συνεχώς στους καταχωρητές του SM
  - Κάθε SM χρονοδρομολογεί διαδοχικά ομάδες threads με **τον ίδιο program counter** (PC) στα cores

Ιδιαιτερότητες εκτέλεσης SIMT

- Τι συμβαίνει στις διακλαδώσεις;

```
if cond {
  A;
}
else {
  B;
}
```

- Η ομάδα των threads με ίδιο PC πρέπει να εκτελεστεί **δύο φορές**
  - την 1η φορά με ενεργοποιημένα μόνο τα threads που εκτελούν τον κώδικα A
  - και τη 2η φορά με ενεργοποιημένα τα threads που εκτελούν το B

Ιδιαιτερότητες εκτέλεσης SIMT

- Αν ένα thread της ομάδας δεν μπορεί να προχωρήσει (π.χ. αναμονή για πόρους);
  - Όλη η ομάδα threads πρέπει να περιμένει
  - Το SM επιλέγει άλλη ομάδα threads που είναι έτοιμη να εκτελεστεί
  - Προσοχή στα barriers: πρέπει να εκτελούνται εκτός διακλαδώσεων (δηλαδή, από όλα τα threads της ομάδας)
- Τα παραπάνω προσπαθούν να διορθώσουν νεώτερες αρχιτεκτονικές GPU
  - Επιτρέποντας ανεξάρτητο PC ανά thread
  - Η μέγιστη απόδοση όμως επιτυγχάνεται όταν όλα τα threads της ομάδας εκτελούν τον ίδιο κώδικα

Το προγραμματιστικό μοντέλο CUDA

- Ένας τρόπος «αφαιρετικής» περιγραφής του hardware (threads, cores, SMs) σε ένα προγραμματιστικό interface
  - Και οι βιβλιοθήκες και εργαλεία που το υλοποιούν
- Για να καλυφθούν με ενιαίο τρόπο GPUs με διαφορετικά χαρακτηριστικά και δυνατότητες
  - Κάποια γνώση των ιδιαιτεροτήτων του hardware είναι παρόλα αυτά αναγκαία

Ορολογία CUDA

- **Kernel**: μια συνάρτηση, περιγράφει τι θα εκτελεστεί στη GPU από (κάθε) ένα thread
- **Thread**: η μικρότερη μονάδα εκτέλεσης του κώδικα του kernel
- **Block**: μια ομάδα threads που εκτελούν τον ίδιο kernel,
  - Εκτελούνται στο ίδιο SM
  - Αν υπάρχουν πόροι (hardware), το SM μπορεί να εκτελεί και άλλο block παράλληλα
- **Grid**: το σύνολο των blocks που εκτελούν τον kernel
  - Σε πρόσφατες GPU υπάρχει και το cluster, μεταξύ block και grid

CUDA block

- Μια ομάδα από threads που εκτελούνται ταυτόχρονα σε ένα SM
- Τα threads αυτά μοιράζονται τους καταχωρητές (registers) και την κοινή μνήμη (shared memory) του SM
  - Κάθε thread έχει δεσμευμένο το δικό του μέρος από τα παραπάνω όσο διαρκεί η εκτέλεση του block
- Τα threads ενός block μπορούν να συγχρονιστούν μεταξύ τους
  - Αντιθέτως, δεν υπάρχει τρόπος να συγχρονιστούν διαφορετικά blocks μεταξύ τους
  - Ούτε μπορούμε να υποθέσουμε με ποια σειρά θα εκτελεστούν τα blocks

Εκτέλεση kernel

- Ο προγραμματιστής ζητά την εκτέλεση ενός kernel με συγκεκριμένο αριθμό **blocks ανά grid** και **threads ανά block**
- Τα blocks που αποτελούν το grid του kernel κατανέμονται στα SM της GPU
- Τα SM εκτελούν τα blocks που τους αντιστοιχούν, το ένα μετά το άλλο ή παράλληλα (ανάλογα με τους διαθέσιμους πόρους)
- Κάθε SM χρονοδρομολογεί ομάδες από threads του ίδιου block για εκτέλεση από τα cores του
  - Σε ομάδες με τον ίδιο PC (“warps” στην ορολογία CUDA, 32 threads με την τρέχουσα τεχνολογία)

Παραμετρική εκτέλεση

- Πώς γνωρίζει κάθε thread ποιο μέρος της συνολικής εργασίας θα εκτελέσει
- Κάθε thread έχει διαθέσιμες κατά την εκτέλεση του kernel μια σειρά από μεταβλητές index
- Οι μεταβλητές αυτές μπορούν να οργανωθούν σε 1, 2 ή 3 διαστάσεις
  - Προγραμματιστική ευκολία, για να ταιριάζουν με το είδος (και την τοπικότητα των δεδομένων) της εφαρμογής
  - Δεν αλλάζει η υποκείμενη οργάνωση σε threads/blocks/grid

Οργάνωση σε μία διάσταση

- Μεταβλητές:
  - threadIdx.x = «ποιο thread του block είμαι»
  - blockIdx.x = «σε ποιο block ανήκω»
  - blockDim.x = «πόσα threads υπάρχουν σε κάθε block»
  - gridDim.x = «πόσα blocks υπάρχουν στο grid»
- Σε οργανώσεις με 2 ή 3 διαστάσεις υπάρχουν επιπλέον τα .y και .z των παραπάνω μεταβλητών
- Για όλα τα παραπάνω κάθε GPU έχει περιορισμούς στον μέγιστο αριθμό τους, όπως και στο πόσα threads/block ή blocks/grid μπορούν να εκτελεστούν

Άσκηση #1: Το 1ο πρόγραμμα CUDA

- Υπόδειγμα: **one-addition.cu**, πρόσθεση σε 1 thread / 1 block
  - Τυπική ροή:
    1. Δέσμευση μνήμης στη συσκευή GPU (device)
    2. Μεταφορά δεδομένων στη GPU
    3. Εκτέλεση ενός kernel
    4. Μεταφορά των αποτελεσμάτων πίσω στη μνήμη του υπολογιστή (host)
    5. Αποδέσμευση μνήμης στη συσκευή
  - **nvcc** compiler, στέλνει την κλασσική C/C++ στον gcc (ή αντίστοιχο) ενώ χειρίζεται διαφορετικά τις επεκτάσεις (extensions) της CUDA

Άσκηση #1: Το 1ο πρόγραμμα CUDA

- Συνδεθείτε στο σύστημα δοκιμών
- Μεταφέρετε το πρόγραμμα .cu στον φάκελό σας
- Χρησιμοποιήστε το nvcc για τη μεταγλώττιση
- Εκτελέστε το πρόγραμμα

Άσκηση #2: Πρόσθεση διανυσμάτων

- Υπόδειγμα: vectoradd-threads-only.cu
  - Πρόσθεση διανυσμάτων float μεγέθους N = 100
    - 1 block / N threads
  - Κάθε thread εκτελεί την πράξη c[i] = a[i]+b[i]
    - Παρατηρήστε πώς ορίζεται το i μέσω του **threadIdx.x**
  - Δοκιμάστε με μεγαλύτερο N
    - Μέχρι ποιο μέγεθος μπορείτε να φτάσετε;
    - Χρησιμοποιήστε το **deviceQuery.cpp** για να δείτε τα όρια της συγκεκριμένης GPU

Άσκηση #2: Πρόσθεση διανυσμάτων

- Δοκιμάστε να αλλάξετε το πρόγραμμα έτσι ώστε να εκτελεί την πρόσθεση των διανυσμάτων με N blocks / 1 thread
  - Πώς θα ορίσετε το i αυτή τη φορά;
  - Ξεκινήστε με N = 10000
    - Ποιο είναι το όριο που μπορείτε να φτάσετε στο μέγεθος του N;

Άσκηση #2: Πρόσθεση διανυσμάτων

- Δοκιμάστε με συνδυασμό αριθμού threads και blocks
  - threads = 256 (σταθερά)
  - blocks = (N+threads-1)/threads (η παλιά καλή φόρμουλα για να βρούμε τον αριθμό blocks που καλύπτει το N)
  - Πώς υπολογίζεται τώρα το i;
    - **Προσοχή**: τώρα μπορεί να εμφανιστεί i >= N, πρέπει να προβλεφθεί στον κώδικα!
  - Δοκιμάστε με N = 10.000.000
    - Μέχρι ποιο μέγεθος N μπορείτε να φτάσετε;
  - Εναλλακτικά: grid-striding loop
    - threads = 256, blocks = πολλαπλάσιο του αριθμού των SM (π.χ. 2...32 φορές)
    - Επανάληψη σε κάθε thread, με βήμα το μέγεθος του grid (= blocks * threads ή αλλιώς gridDim.x * blockDim.x)