Ιόνιο Πανεπιστήμιο – Τμήμα Πληροφορικής
Παράλληλος Προγραμματισμός
2023-24

Λειτουργίες reduction σε GPU

(Εισαγωγή σε συγχρονισμό και shared memory)

https://mixstef.github.io/courses/parprog/

Το εργαστήριο του μαθήματος χρησιμοποιεί υπολογιστικούς πόρους AWS Cloud χρηματοδοτούμενους από το ΕΔΥΤΕ

Μ.Στεφανιδάκης

Reduction

- Συνδυάζει όλα τα στοιχεία μιας συλλογής (collection) σε ένα μοναδικό στοιχείο μέσω τελεστή *f*

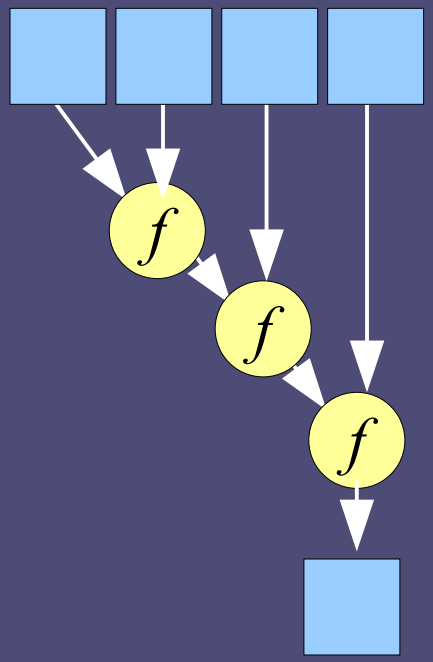

Reduction σε GPU

- Απαιτείται κάποιου είδους συγχρονισμός
  - Για την παραγωγή ενός και μοναδικού τελικού αποτελέσματος
- Τι γνωρίζουμε ως τώρα;
  - Το μόνο είδος συγχρονισμού που έχουμε συναντήσει είναι έμμεσο, μετά την ολοκλήρωση του kernel
    - Πριν τη μεταφορά των αποτελεσμάτων πίσω στο host
    - Εγγύηση ότι έχουν τελειώσει όλα τα threads, όλων των blocks, για το σύνολο του grid
  - Γνωρίζουμε επίσης ότι δεν μπορεί να υπάρξει συγχρονισμός μεταξύ των διαφορετικών blocks
    - Δεν γνωρίζουμε καν με ποια σειρά θα εκτελεστούν τα blocks

Reduction: πρώτες απόπειρες

- 1 thread / 1 block
  - Αναπαραγωγή του σειριακού προγράμματος
  - Αδικαιολόγητη σπατάλη υπολογιστικών πόρων της GPU
- K threads / 1 block (π.χ. K=256)
  - Κάθε thread αθροίζει μια ομάδα στοιχείων του array εισόδου
    - Το αποτέλεσμα είναι ένα array μερικών αποτελεσμάτων
  - Ο υπολογισμός του τελικού αποτελέσματος (συνδυασμός μερικών αθροισμάτων) πρέπει να γίνει
    - Είτε στο host (CPU) – ok γιατί τα μερικά αποτελέσματα είναι λίγα
    - Είτε από δεύτερο kernel που ακολουθεί – στη default λειτουργία οι kernels εκτελούνται ο ένας μετά τον άλλον

Αν αυξήσουμε τον αριθμό των blocks;

- **Η λύση δεν είναι επεκτάσιμη**
  - Τα μερικά αθροίσματα συνεχώς θα μεγαλώνουν σε μέγεθος (blocks * threads)
- **Αν κάθε block συνδύαζε όλα τα μερικά αποτελέσματα των threads του σε έναν αριθμό;**
  - Τα μερικά αθροίσματα θα έχουν μέγεθος ίσο με τον αριθμό των blocks
    - Διαχειρίσιμο μέγεθος, ακόμα κι από CPU
  - Το τελικό αποτέλεσμα πρέπει όπως και πριν να υπολογιστεί **μετά τη λήξη** του συνολικού kernel
    - Θυμηθείτε: δεν μπορούμε να συγχρονίσουμε τα blocks μεταξύ τους!

Reduction σε ένα block

- Η γενική ιδέα
  - Reduction σε βήματα
  - Σε κάθε βήμα ο αριθμός των threads που είναι ενεργά υποδιπλασιάζεται
  - Το τελευταίο thread παράγει το μερικό αποτέλεσμα για το block

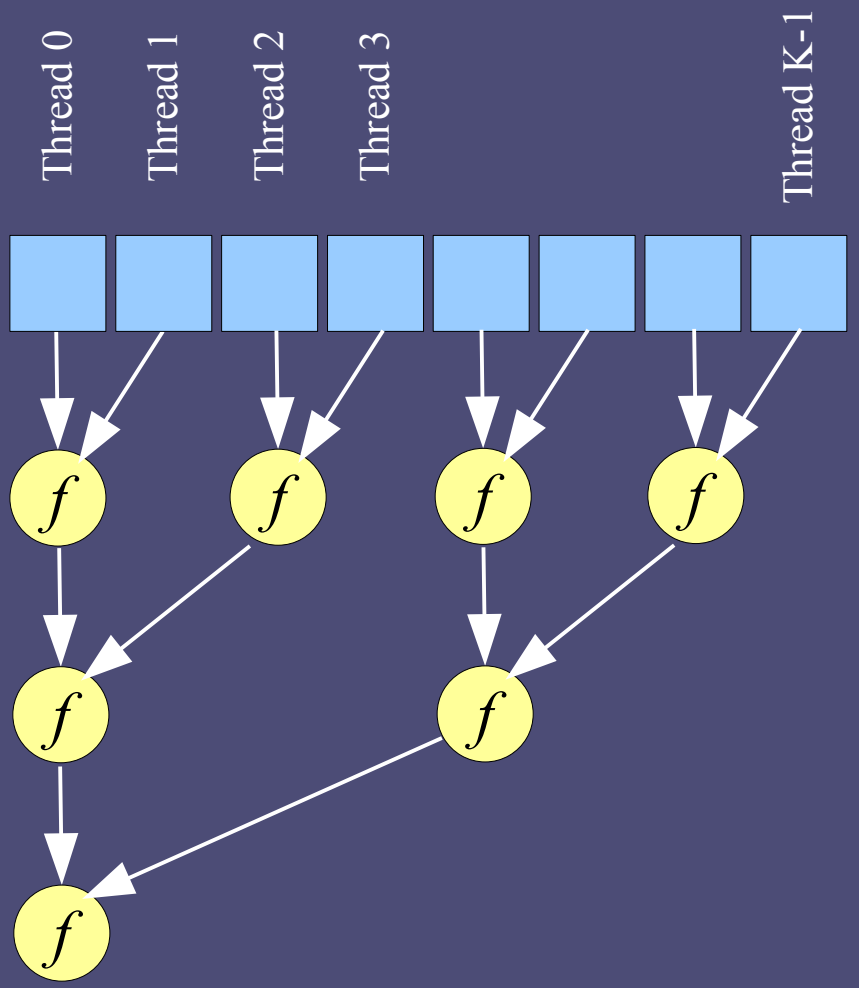

Reduction σε ένα block: προβλήματα

- Συγχρονισμός μεταξύ threads
  - Σε κάθε βήμα πρέπει να είμαστε σίγουροι ότι τα threads που συμμετείχαν στο προηγούμενο βήμα έχουν τελειώσει
- Χώρος αποθήκευσης
  - Απαιτείται η προσπέλαση δεδομένων από άλλα threads
    - Δεν μπορούμε να χρησιμοποιήσουμε καταχωρητές (ξεχωριστοί ανά thread)
    - Χρειαζόμαστε έναν κοινό χώρο (shared memory) πιο γρήγορο από την κύρια μνήμη της GPU
- Σειρά υπολογισμού
  - Το σχήμα στην προηγούμενη διαφάνεια δεν είναι βέλτιστο
    - Μεγάλος βαθμός απόκλισης εκτέλεσης των threads στα warps
    - Μη αποδοτική προσπέλαση μνήμης

Συγχρονισμός threads του ίδιου block

```
// synchronize all threads of block
__syncthreads();
```

- Πρέπει να εκτελεστεί από όλα τα threads του block
  - Για να συνεχιστεί η εκτέλεση μετά το σημείο αυτό
- Προσοχή! Δεν πρέπει να μπαίνει σε τμήματα κώδικα υπό συνθήκη (if..)
  - Αν κάποια threads του block δεν εκτελέσουν το __syncthreads() τότε η εκτέλεση στο block αυτό θα «παγώσει»

Shared Memory

- Μικρή γρήγορη μνήμη μέσα σε κάθε SM
  - Σε ιδανικές συνθήκες σχεδόν τόσο γρήγορη όσο οι καταχωρητές
  - Τυπικά μεγέθη 64KB έως 96KB
  - Μοιράζεται τον χώρο με L1 Cache/Texture memory
- Δέσμευση ατομικού χώρου ανά block
  - Για όλη τη διάρκεια εκτέλεσης του block
  - Διαθέσιμη σε όλα τα threads του block

Δήλωση χώρου από το shared memory

```
__global__ void sumReduction(float *a,float *psums) {
    __shared__ float buffer[THREADS];
```

- Στο παράδειγμα φαίνεται η δήλωση με στατικό μέγεθος, μέσα στον κώδικα του kernel
  - Υπάρχει και η δυνατότητα δήλωσης με δυναμικό μέγεθος (ως τρίτη παράμετρος στην εκκίνηση του kernel) αλλά δεν θα τη χρησιμοποιήσουμε εδώ

Βελτιωμένο σχήμα reduction ενός block

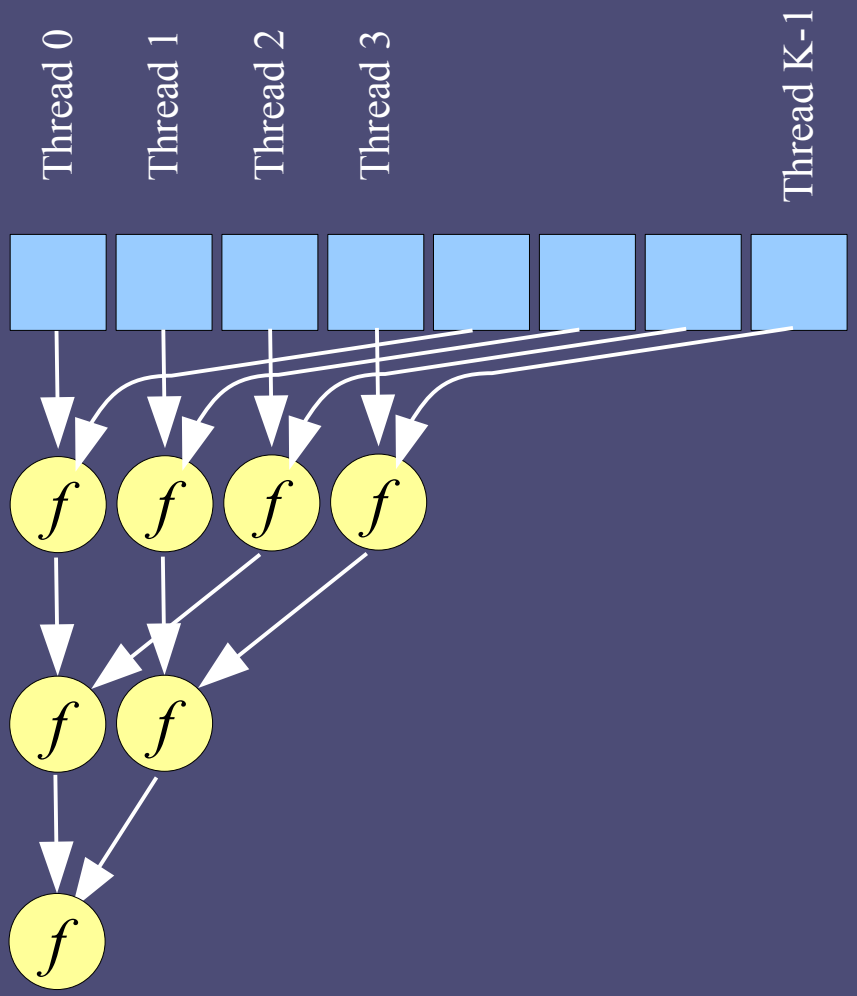

Παράδειγμα κώδικα για το reduction στο block

```
// reduce block results, number of threads must be a power of 2

for (unsigned int stride = blockDim.x/2; stride>0; stride /= 2)
{
  if (tid<stride) {
    buffer[tid] += buffer[tid+stride];
  }

  // synchronize all threads of block before next step
  __syncthreads();

}
```

- Σε κάθε βήμα τα threads που βρίσκονται στο «κάτω μισό» προσθέτουν την αντίστοιχη τιμή από το «πάνω μισό»
  - tid είναι το threadIdx.x
- Ο χώρος μειώνεται στο μισό και επαναλαμβάνουμε στο επόμενο βήμα