Ιόνιο Πανεπιστήμιο – Τμήμα Πληροφορικής ΠΜΣ «Ερευνητικές Κατευθύνσεις στην Πληροφορική» Παράλληλη και Κατανεμημένη Υπολογιστική Επεξεργασία 2019-20

Ιεραρχίες Μνήμης

(και ο ρόλος τους στην απόδοση της παράλληλης επεξεργασίας)

http://mixstef.github.io/courses/pms-parcomp/



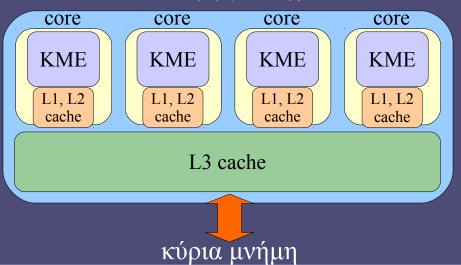
Μ. Στεφανιδάκης

Ιεραρχίες Μνήμης

- Πολλαπλά επίπεδα κρυφής μνήμης (cache memory)
 - Μεταξύ ΚΜΕ και κύριας μνήμης
 - Προσπάθεια γεφύρωσης της διαφοράς απόδοσης κατά την προσπέλαση δεδομένων μεταξύ επεξεργαστικών στοιχείων και κύριας μνήμης σε ένα υπολογιστικό σύστημα
 - Η προσπέλαση της κύριας μνήμης είναι τυπικά της τάξης του 100x αργότερη από την προσπέλαση δεδομένων σε καταχωρητές

Κρυφές μνήμες

- Γρηγορότερη προσπέλαση δεδομένων
 - L1: τυπικά 1-4 κύκλοι ρολογιού
 - L2-L3: τυπικά 10-20 κύκλοι ρολογιού
 - Κύρια μνήμη: τυπικά 100 κύκλοι ρολογιού
- Συμμετοχή στο σχήμα της «κοινής μνήμης» επεξεργαστής



Κρυφές μνήμες: Χωρητικότητα

- Κάθε επίπεδο αποθηκεύει μικρό μέρος του αμέσως κατώτερου
 - L1: μερικές δεκάδες ΚΒ
 - Συνήθως χωρισμένα σε κρυφή μνήμη εντολών (L1I) και κρυφή μνήμη δεδομένων (L1D)
 - L2: μερικά MB
 - L3: μερικές δεκάδες MB
- Η ταχύτητα προσπέλασης μειώνεται με την αύξηση του μεγέθους
 - Αλλά είναι σε κάθε περίπτωση γρηγορότερη από την κύρια μνήμη
 - Δεν επηρεάζει την ΚΜΕ βλέπει την ταχύτερη κρυφή μνήμη

Γιατί (πότε) επιτυγχάνει η ιεραρχία μνήμης

- Οι κρυφές μνήμες χωρούν πολύ μικρό μέρος των δεδομένων της κύριας μνήμης
 - Μικρότερος χώρος όσο πλησιάζουμε τον επεξεργαστή
 - Διαφορετικά δεδομένα μοιράζονται τις ίδιες θέσεις σε κάθε επίπεδο της κρυφής μνήμης
 - Ανταγωνίζονται και αντικαθιστούν άλλα δεδομένα
 - Κάποια δεδομένα δεν θα είναι διαθέσιμα στις κρυφές μνήμες όταν τα ζητήσει κάποια ΚΜΕ
- Για να είναι επιτυχημένη η ιεραρχία μνήμης θα πρέπει η ΚΜΕ να βρίσκει συχνά τα δεδομένα που χρειάζεται στις κρυφές μνήμες
 - Ποιος το εγγυάται αυτό;

Τοπικότητα κατά την επεξεργασία

• Χρονική Τοπικότητα

- Εάν προσπελαστεί μια θέση μνήμης, είναι πολύ πιθανό να προσπελαστεί ξανά στο άμεσο μέλλον
- Ό,τι χρησιμοποιήθηκε θα ζητηθεί ξανά πολύ σύντομα
 - Συνεπώς θα βρίσκεται ακόμα στην κρυφή μνήμη με μεγάλη πιθανότητα

• Χωρική Τοπικότητα

- Εάν προσπελαστεί μια θέση μνήμης, είναι πολύ πιθανό να προσπελαστούν και οι γειτονικές θέσεις στο άμεσο μέλλον
 - Όταν δεν αρκεί η χρονική τοπικότητα
- Για να εκμεταλλευτούμε την χωρική τοπικότητα πρέπει να μετακινούμε μπλοκ δεδομένων από/προς την κύρια μνήμη

Μεταφορές σε μπλοκ

- Ολες οι μεταφορές μεταξύ κύριας μνήμης και κρυφών μνημών γίνεται σε μπλοκ λέξεων
 - Τυπικό μέγεθος 64 bytes (cache line)
 - Μόνο οι ΚΜΕ διαβάζουν/γράφουν μεμονωμένες λέξεις
- Αντικατάσταση μπλοκ
 - Όταν ένα νέο μπλοκ εισάγεται σε μία κρυφή μνήμη
 - Θα πρέπει να επιλεγεί ποιο υπάρχον μπλοκ θα αντικατασταθεί (victim)
 - Η επιλογή γίνεται ανάλογα με την πολιτική τοποθέτησης
 της κρυφής μνήμης

Πολιτικές τοποθέτησης

- Direct mapped cache
 - Επιλογή θέσης από ένα μέρος των bits της διεύθυνσης του μπλοκ
 - Γρήγορος υπολογισμός και αναζήτηση
 - «Τυφλή» αντικατάσταση χρήσιμων μπλοκ
- Fully associative cache
 - Ένα μπλοκ μπορεί να τοποθετηθεί παντού
 - Least Recently Used
 - Χρονοβόρα αναζήτηση
- N-way set-associative cache
 - Τοποθέτηση σε μία από Ν (4, 8, ..) θέσεις (σετ)
 - Συμβιβασμός μεταξύ των δύο προηγούμενων

Λειτουργία κρυφής μνήμης

- Διαφανής λειτουργία αυτόματη διαχείριση από υλικό
 - Οι ΚΜΕ εκτελούν αναγνώσεις (reads) και εγγραφές (writes)
 λέξεων δεδομένων από/προς το κοντινότερο επίπεδο
 κρυφής μνήμης (L1)
 - Αν βρεθεί το μπλοκ που περιέχει τη λέξη (hit)
 - Κατά την ανάγνωση, η λέξη επιστρέφεται στην ΚΜΕ
 - · Κατά την εγγραφή συνήθως η λέξη εγγράφεται μόνο στην κρυφή μνήμη (πολιτική write-back)
 - Αν δεν βρεθεί (miss) ζητείται από το χαμηλότερο επίπεδο το μπλοκ που περιέχει τη λέξη
 - Συνήθως αυτό συμβαίνει και κατά την εγγραφή (πολιτική write allocate)
 - Σε αντικατάσταση μπλοκ με αλλαγές, πρέπει πρώτα να γραφτεί αυτό στο χαμηλότερο επίπεδο

Λειτουργία κρυφής μνήμης

- Prefetching «προληπτική» μεταφορά δεδομένων
 - Μπορεί να εκτελείται αυτόματα από το υλικό
 - Όταν εντοπίσει ένα σχέδιο αλληλουχίας προσπελάσεων
 - Ή από το λογισμικό με ειδικές εντολές prefetch
- Non-temporal stores
 - Σε πολλές εφαρμογές υπολογισμού υψηλής απόδοσης
 τύπου streaming τα αποτελέσματα δεν θα χρησιμοποιηθούν ξανά
 - Πρέπει να αποφευχθεί η «μόλυνση» της κρυφής μνήμης με μπλοκ που δεν θα χρειαστούν
 - Υπάρχουν εντολές εγγραφής που παρακάμπτουν την κρυφή μνήμη

Επίδραση στην παράλληλη επεξεργασία

- Πολλά υπολογιστικά προβλήματα εξαρτώνται από τον ρυθμό μεταφοράς δεδομένων από/προς τη μνήμη
 - Memory-bound problems
 - Μικρές ευκαιρίες βελτίωσης
- Όταν τα δεδομένα χωρούν στις κρυφές μνήμες
 - Η προσπέλαση των δεδομένων πρέπει να εκμεταλλεύεται την προσφερόμενη τοπικότητα έτσι ώστε να επιτυγχάνεται αύξηση της απόδοσης
- False sharing
 - Όταν πολλαπλά threads ανταγωνίζονται για ένα μπλοκ δεδομένων χωρίς να προσπελαύνουν την ίδια λέξη

Επίσης: η επίδραση της εικονικής μνήμης

Virtual memory

- Σχήμα μετάφρασης των λογικών διευθύνσεων μνήμης των εφαρμογών σε φυσικές διευθύνσεις μνήμης
- Οργάνωση σε σελίδες (pages)
- Συνεργασία υλικού-λογισμικού
 - Πίνακες σελίδων (διαχείριση από λειτουργικό σύστημα)
 - Διαφορετικοί πίνακες για κάθε εφαρμογή
 - Οι ΚΜΕ μεταφράζουν λογικές διευθύνσεις μνήμης σε φυσικές σε κάθε προσπέλαση
 - Δηλαδή περισσότερες προσπελάσεις (για να πάρει η ΚΜΕ την πληροφορία από τους πίνακες σελίδων) για κάθε μία προσπέλαση δεδομένων;!;!;

Η επίδραση της εικονικής μνήμης

- Πώς αποφεύγεται η συνεχής προσπέλαση των πινάκων σελίδων
 - Μηχανισμός page table walking
- Translation Lookaside Buffer (TLB)
 - Μικρή «κρυφή μνήμη» με πρόσφατες μεταφράσεις (π.χ. 128 θέσεις)
 - Πολύ περιορισμένος πόρος
 - Εάν τα δεδομένα ανήκουν σε πολλαπλές σελίδες πιθανόν να υπάρχουν αυξημένα TLB misses
 - Το μέγεθος της σελίδας συνήθως είναι μικρό (4KB-2MB)

Βιβλιογραφία

- Michael McCool, James Reinders, and Arch Robison. 2012. Structured Parallel Programming: Patterns for Efficient Computation (1st ed.). Morgan Kaufmann Publishers Inc., San Francisco, CA, USA.
- Georg Hager and Gerhard Wellein. 2010. Introduction to High Performance Computing for Scientists and Engineers (1st ed.). CRC Press, Inc., Boca Raton, FL, USA.