Εργαστήριο Σημασιολογικού Ιστού

Ενότητα 8: Εισαγωγή στη SPARQL – Βασική Χρήση

Μ.Στεφανιδάκης

3-5-2018

Η γλώσσα ερωτημάτων SPARQL

- Ερωτήσεις (και ενημερώσεις) σε σετ δεδομένων RDF
  - Και σε δεδομένα άλλης μορφής που μπορούν να αναπαρασταθούν ως τριάδες, χωρίς απαραίτητα να είναι δεδομένα RDF!
    - Δεδομένα από σχεσιακές βάσεις
    - Δεδομένα σε μορφή spreadsheet
    - Και οτιδήποτε άλλο περικλείει σημασιολογική πληροφορία
- Ένα “παράθυρο” σε βάσεις σημασιολογικών δεδομένων
  - Διεπαφή (interface) για αλληλεπίδραση με τις εφαρμογές χρήστη
  - Υλοποίηση από “SPARQL engines”

SPARQL engines

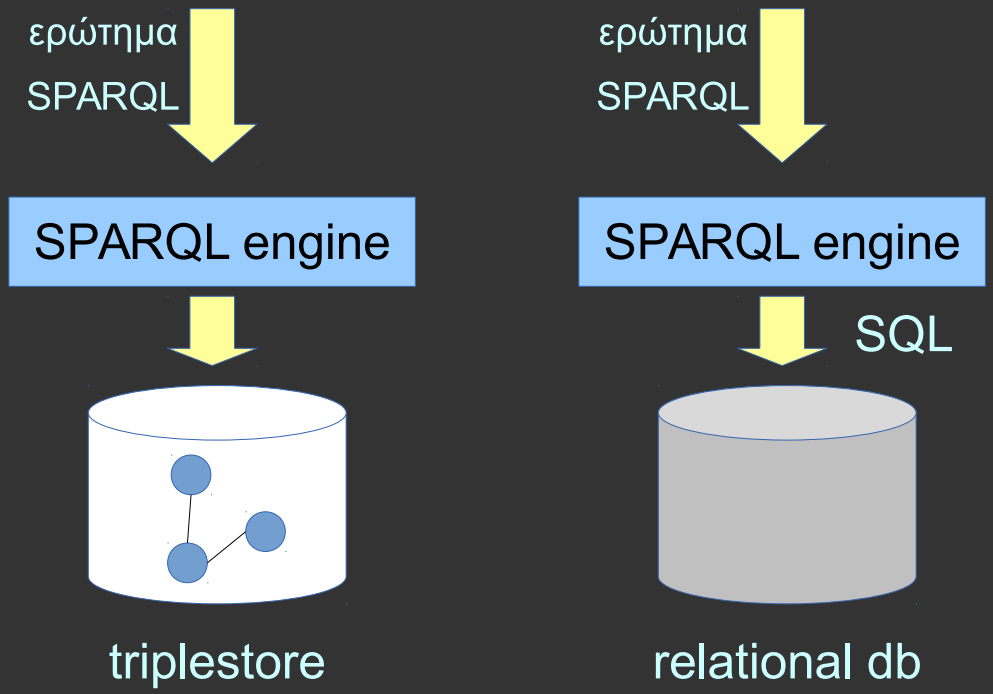

- Συνοδεύουν απαραίτητα βάσεις τριάδων RDF (triplestores)
- Και υπάρχουν συχνά ως ενδιάμεσο λογισμικό (middleware) σε σχεσιακές βάσεις ή άλλα σετ (μη RDF) δεδομένων
- Όταν μπορούν να προσπελαστούν μέσω Web, μιλάμε για SPARQL endpoints

Το πρότυπο της γλώσσας SPARQL

- Τρέχουσα έκδοση: SPARQL 1.1 (2013)
- Μια σειρά από προδιαγραφές που περιγράφουν
  - Τη σύνταξη και σημασιολογία των ερωτημάτων SPARQL
  - Τη μορφή των επιστρεφόμενων απαντήσεων
  - Τον τρόπο αποστολής ερωτημάτων μέσω HTTP
  - Τη σύνταξη των αιτημάτων ενημέρωσης των δεδομένων (update)
  - Πρόσθετα θέματα όπως
    - Τη μέθοδο περιγραφής προσφερόμενων υπηρεσιών
    - Τη λειτουργία διεξαγωγής κατανεμημένων ερωτημάτων
    - Τον τρόπο συνεπαγωγής πρόσθετης γνώσης (entailment regimes)

Η παλαιότερη έκδοση SPARQL 1.0 (2008)

- Περιγράφει μέρος μόνο της λειτουργικότητας της νεώτερης SPARQL 1.1
- Αλλά παραμένει σημαντική:
  - Είναι η ελάχιστη εγγυημένη λειτουργικότητα από κάθε SPARQL engine που θα συναντήσετε on-line...
    - Υπάρχει ακόμα λογισμικό που δεν υποστηρίζει τα νέα χαρακτηριστικά της SPARQL 1.1
    - Ακόμα κι αν έχουν βγει ενημερώσεις, κανείς δεν εγγυάται ότι αυτές έχουν εφαρμοστεί σε κάθε βάση RDF στο Web
  - Μια ευέλικτη εφαρμογή θα πρέπει να μπορεί να λειτουργήσει ικανοποιητικά χωρίς να βασίζεται απόλυτα στα νέα χαρακτηριστικά της SPARQL 1.1
    - Παρά μόνο χρησιμοποιώντας τα προσθετικά, ως βελτιώσεις, όταν είναι διαθέσιμα

Παράδειγμα ερωτήματος SELECT της SPARQL

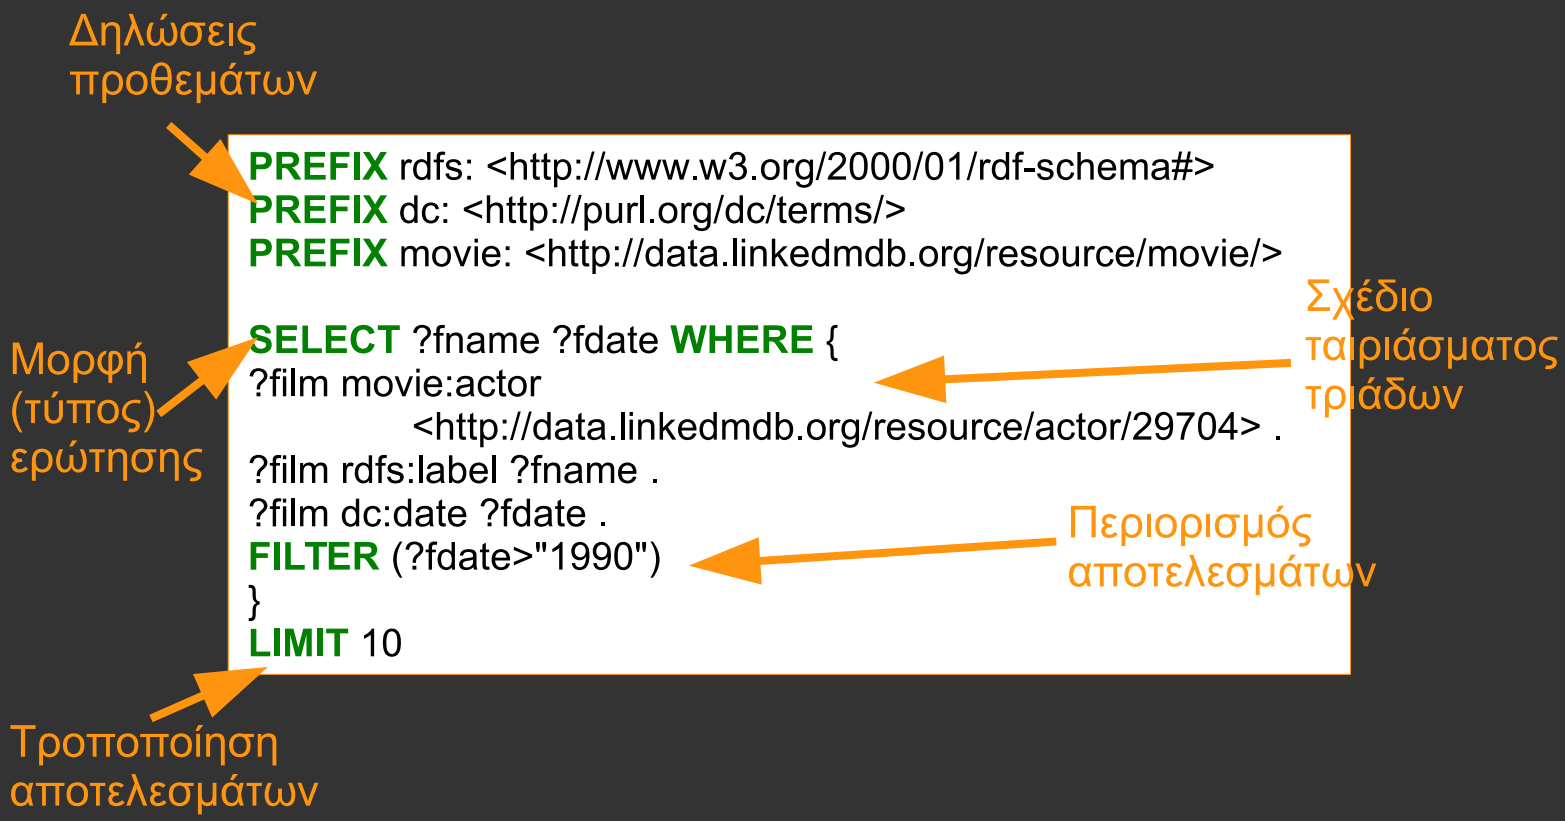

- Η σύνταξη γενικά αγνοεί κενά και newlines, κεφαλαία-πεζά
- μόνο το ειδικό κατηγόρημα a (rdf:type) πρέπει να γραφεί με πεζά
- Δοκιμάστε κι εσείς το πιο πάνω ερώτημα!

Βοηθητικές Συντομογραφίες

- Η SPARQL βασίζεται στη σύνταξη των τριάδων σύμφωνα με την Turtle, μια πιο συνοπτική γλώσσα περιγραφής τριάδων RDF από τη μορφή NTriples
  - Συντομογραφίες τριάδων: όταν έχουν κοινό υποκείμενο μπορείτε να γράψετε

```
?x  foaf:name  ?name ;   αντί για    ?x  foaf:name  ?name .
    foaf:mbox  ?mbox .               ?x  foaf:mbox  ?mbox .
```

  - και όταν έχουν κοινό υποκείμενο και κατηγόρημα μπορείτε να γράψετε

```
?x foaf:nick  "Alice" , "Alice_" .  αντί για   ?x  foaf:nick  "Alice" .
                                               ?x  foaf:nick  "Alice_" .
```

  - Σταθερές τιμές (Literals): μπορείτε να γράψετε τις αριθμητικές τιμές χωρίς εισαγωγικά και χωρίς τύπο δεδομένων
    - π.χ. το σκέτο 57 είναι ισοδύναμο με το `"57"^^xsd:integer`

Μορφές ερωτημάτων (Query Forms)

- Η SPARQL (ήδη από την έκδοση 1.0) παρέχει 4 τύπους ερωτημάτων:
  - SELECT: όπως είδαμε στο βασικό παράδειγμα, ταιριάζει σχέδια (patterns) τριάδων και επιστρέφει τις τιμές που ανατέθηκαν στις μεταβλητές του ερωτήματος
  - CONSTRUCT: ταιριάζει σχέδια (patterns) τριάδων και χρησιμοποιεί τις τιμές που ανατέθηκαν στις μεταβλητές για να κατασκευάσει έναν νέο γράφο
  - ASK: επιστρέφει TRUE ή FALSE αν υπάρχουν ταιριάσματα για τη συγκεκριμένη ερώτηση ή όχι
  - DESCRIBE: επιστρέφει έναν νέο γράφο με “ενδιαφέρουσα πληροφορία” για τις οντότητες που ταιριάζει η ερώτηση
    - Το πρότυπο της SPARQL δεν περιγράφει τι πρέπει να επιστρέφεται, συνήθως οι τριάδες που περιέχουν τις οντότητες ως υποκείμενα ή αντικείμενα

SELECT και WHERE

ερώτημα

```
SELECT ?x ?y WHERE
{
  ?x  p  B .
  B   q  ?y .
}
```

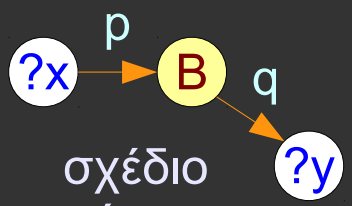

σχέδιο ταιριάσματος

γράφος

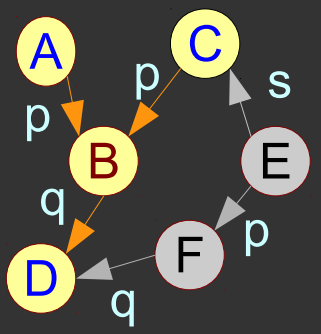

WHERE

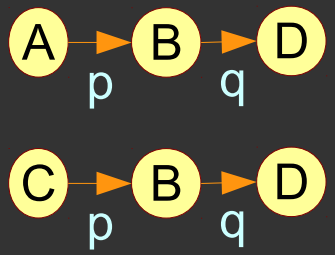

αποτέλεσμα

?x	?y
A	D
C	D

SELECT

- WHERE: επιλέγει τριάδες που ταιριάζουν
- SELECT: επιλέγει δεδομένα από τις τριάδες που ταίριαξαν
  - Προσοχή: η έξοδος του SELECT δεν είναι τριάδες αλλά πίνακας λύσεων!

Τροποποιώντας τα αποτελέσματα

- Όταν η SELECT έχει έτοιμα τα αποτελέσματα, μπορείτε να αλλάξετε τη σειρά τους ή το πλήθος τους:
  - DISTINCT: απαλοιφή πανομοιότυπων λύσεων
    - `SELECT DISTINCT ... WHERE { ... }`
    - Η απαλοιφή γίνεται μετά την ταξινόμηση αλλά πριν την εφαρμογή LIMIT και OFFSET
    - Το γράφετε αμέσως μετά το SELECT
  - ORDER BY: ταξινόμηση αποτελεσμάτων με βάση κάποια κριτήρια
    - `SELECT ... WHERE { ... }`
      `ORDER BY ?name DESC(?age)`
    - Το γράφετε πριν τα LIMIT και OFFSET, μετά το WHERE
  - LIMIT και OFFSET: ρυθμίζουν το πλήθος και το σημείο έναρξης λήψης των αποτελεσμάτων
    - `SELECT ... WHERE { ... } LIMIT 10 OFFSET 20`
    - Προφανώς, για να τα χρησιμοποιήσετε για σελιδοποίηση (pagination), θα πρέπει πρώτα να τα ταξινομήσετε!

Δοκιμάζοντας τη SPARQL off-line

- Για να θέσετε δοκιμαστικά ερωτήματα SPARQL σε δεδομένα ενός εγγράφου RDF μπορείτε να χρησιμοποιήσετε στο εργαστήριο:
  - Το command-line εργαλείο `arq`, το οποίο περιλαμβάνεται στο Apache Jena Framework
    - `arq --query test.rq --data test.nt`
  - Το command-line εργαλείο `roqet`, από τη βιβλιοθήκη Redland RDF
    - `roqet -D test.nt test.rq`

Η σειρά σας!

- Χρησιμοποιήστε το σετ δεδομένων RDF για το ωρολόγιο πρόγραμμα με το arq για να θέσετε τα παρακάτω ερωτήματα (εκφράστε τα σε SPARQL):
  1. Ποιες οι διαλέξεις την Τρίτη;
  2. Ποιες οι διαλέξεις την Τρίτη και σε ποιες ώρες;
  3. Όπως το προηγούμενο αλλά ταξινομήστε με την ώρα έναρξης!
  4. Ημέρες που γίνονται μαθήματα –θυμηθήκατε το DISTINCT;
  5. Ποια τα κατηγορήματα που χρησιμοποιεί το σετ δεδομένων;
  6. Ποιοι διδάσκοντες ξεκινάνε στις 10 το πρωί και ποιες μέρες;
  7. Τα δεδομένα κάθε διάλεξης (μάθημα, ημέρα, έναρξη, λήξη) με ταξινόμηση κατά μάθημα!
  8. Ημέρες και ώρες των διαλέξεων ενός συγκεκριμένου μαθήματος;
  9. Μοναδικά ζεύγη (διδάσκων, μάθημα);
  10. Διδάσκοντες ενός συγκεκριμένου μαθήματος;

Η χρήση του FILTER

- Το FILTER συνοδεύει προαιρετικά ένα σχέδιο ταιριάσματος τριάδων και περιορίζει το σύνολο των προσφερόμενων λύσεων:

```
SELECT DISTINCT ?course WHERE {
 ?s exv:startTime ?start .
 ?course exv:hasLecture ?s .
 FILTER (?start<"15:00:00"^^xsd:time)
}
```

- Ακολουθείται από μια λογική έκφραση (true/false) που καθορίζει αν η συγκεκριμένη λύση θα περιληφθεί στην απάντηση
  - Η έκφραση μπορεί να συγκρίνει αριθμητικές τιμές (τελεστές =, !=, <, <=, > και >=)
  - Ή γενικά όρους για ισότητα και ανισότητα
  - Να καλεί συναρτήσεις της SPARQL (θα δούμε μερικές αργότερα)
  - Και να συνδυάζει όλα τα προηγούμενα με λογικούς τελεστές (&&, || και !)

Αναζητώντας αυτό που δεν υπάρχει

- Ή ορθότερα: αναζητώντας λύσεις που δεν ταιριάζουν στην ερώτηση
- Η SPARQL διαθέτει 3 (!) τρόπους για να το κάνετε, εδώ φαίνεται ο απλούστερος
  - Αλλά μόνο στη SPARQL 1.1!

```
SELECT ?s WHERE {
 ?s a exv:Lecture .
 FILTER NOT EXISTS {
   ?s exv:hasTeacher ?t .
 }
}
```

- Λαμβάνοντας υπόψη τις τιμές των μεταβλητών μετά το κάθε ταίριασμα, το `FILTER NOT EXISTS` ελέγχει ένα δεύτερο σχέδιο ταιριάσματος
  - Αν το τελευταίο δεν έχει λύση, μόνο τότε το πρώτο ταίριασμα γίνεται αποδεκτό

Η σειρά σας!

- Χρησιμοποιήστε το σετ δεδομένων RDF για το ωρολόγιο πρόγραμμα με το arq για να θέσετε τα παρακάτω ερωτήματα (εκφράστε τα σε SPARQL):
  - Μαθήματα που έχουν (και) διαλέξεις πριν το μεσημέρι
  - Διδάσκοντες που διδάσκουν (και) πριν το μεσημέρι
  - Ποιοι διδάσκουν στις 13:00, ποια μέρα και ποιο μάθημα;
  - Ημέρες που υπάρχουν διαλέξεις αλλά όχι στις 10:00

rdflib και ερωτήσεις SELECT της SPARQL

```
import rdflib

# create an RDF graph object
g = rdflib.Graph()

# load a dataset from a file into graph
g.parse("schedule.nt",format='nt')

# the SPARQL query string
qstr = """
PREFIX xsd:  <http://www.w3.org/2001/XMLSchema#>
PREFIX ex: <http://ex.com/resource/>
PREFIX exv: <http://ex.com/myvocab#>

select ?course ?start ?end where {
 ?s exv:imera "triti" .
 ?s exv:mathima ?course .
 ?s exv:enarksi ?start .
 ?s exv:liksi ?end .
}
"""

# query the graph and get results
results = g.query(qstr)

# iterate over result rows
for row in results:
^^Iprint("{} {} {}".format(row['course'],row['start'],row['end']))
^^I# can also access results by index number
^^Iprint("{} {} {}".format(row[0],row[1],row[2]))
```

Η σειρά σας!

- Κατασκευάστε με τη βοήθεια της rdflib απλό πρόγραμμα για υποβολή ερωτήσεων SPARQL στα δεδομένα RDF του ωρολογίου προγράμματος
  - Λειτουργία Α': ο χρήστης δίνει ημέρα της εβδομάδας και το πρόγραμμα επιστρέφει τα μαθήματα (διαλέξεις) για τη μέρα αυτή
  - Λειτουργία Β': ο χρήστης δίνει ημέρα και ώρα και το πρόγραμμα επιστρέφει τα μαθήματα (διαλέξεις) για την ημέρα και ώρα αυτή (αν υπάρχουν)
    - Προσοχή: εδώ πρέπει να χειριστείτε διαστήματα ωρών!
- Μπορείτε να δοκιμάσετε τις ερωτήσεις σας πρώτα με τη βοήθεια του `arq`